Injecting Logical Background for Relation Extraction

Tim Rockt aschel (UCL)

Sameer Singh (UW)

Sebastian Riedel (UCL)

2015 年 5 月 7 日

Outline

- 论文概述
- 矩阵分解 (Matrix factorization), 一阶谓词逻辑 (first-order logic)
- 符号集 (Notation)
- 一阶谓词逻辑注入 (Inject) 矩阵分解
  - 矩阵分解之前操作 (Pre-Factorization)
  - 融入矩阵分解之中 ('joint')
- 实验
  - 预处理, 规则生成, 评价

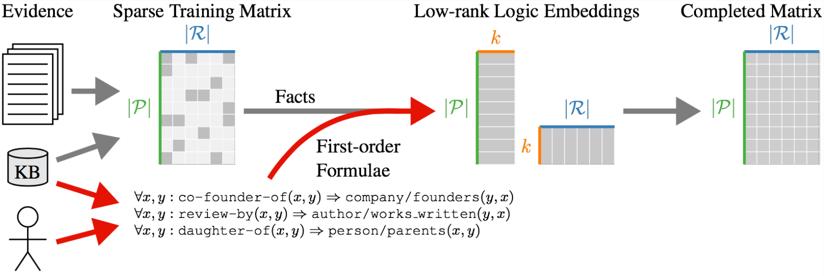

原始矩阵 $|\mathcal{P}| \times |\mathcal{R}|$

	fr1	fr2	fr3	p1	p2	p3	p4	p5	p6
(e1,e2)	1	0	0	0	1	0	0	1	0
(e2,e3)	0	1	0	1	0	0	1	0	0
(e1,e3)	0	0	1	0	0	1	0	0	0
(e1,e10)	1	0	0	1	0	0	0	0	0
(e1,e6)	1	1	0	1	0	0	1	1	0
(e1,e8)	1	0	0	1	0	0	0	0	0
(e3,e7)	0	1	0	1	0	0	1	0	0

- 矩阵分解 (MF) vs 规则抽取 (Rule-based)
  - MF: 开放域、不需要标注数据（弱监督）；完全依赖于 KB 的质量
    - 关系出现次数多，预测才好；不出现的无法预测；
  - Rule-based: 可以发现新的实体，新的关系；噪声大
- 本文动机
  - 矩阵分解和规则（一阶逻辑）混合
- 本文的贡献
  1. 如何在矩阵分解前、后利用谓词逻辑
  2. 利用一阶谓词逻辑训练更好的实体对向量、谓词向量
  3. 结合 MF，FOL 来预测实体的关系

Notation

$\mathcal{P} \subseteq \varepsilon \times \varepsilon$: 实体对 (e_i, e_j) 集合

$\mathcal{R}$: 关系 fr_i, p_j 集合

V: 向量空间 $\{v_{fr_1} = \mathbf{v_{r_m}}, v_{fr_2}, ..., v_{p_1} = \mathbf{v_{(e_i,e_j)}}, v_{p_2}, ...\}$

$\pi_m^{e_i,e_j} = \sigma(\mathbf{v_{r_m}}, \mathbf{v_{(e_i,e_j)}})$: 实体对与关系的相似性 σ:sigmoid func

- 一阶谓词
  - 原子问题（ground Atom）: $professorAt(x, y)$
  - 复合问题（logical background knowledge）: $professorAt(x, y) \Rightarrow emplyeeAt(x, y)$

评价一阶谓词子集 $\mathbf{w}$ 的好坏

$$p(\mathbf{w}|V) = \prod_{r_m(e_i,e_j)\in w} \pi_m^{e_i,e_j} \prod_{r_m(e_i,e_j)\notin w} (1 - \pi_m^{e_i,e_j})$$

Method

1. 传统方法
   - 直接矩阵分解（MF）
   - 只利用逻辑规则（Inf）
2. FOL,MF “混合”模型
   1. FOL 作为预处理（Pre-Factorization Inference）
      - 先用 FOL 改变原始矩阵 $M_{|\mathcal{P}|\times|\mathcal{R}|}$ ，再进行普通矩阵分解
   2. 一阶谓词子集加入目标函数（Joint Optimization）
   3. 传统矩阵分解生成向量空间 V，然后使用收集的逻辑规则预测（Post-Factorization Inference）

一阶逻辑 (FOL) 注入

两种途径

1. FOL 作为预处理（Pre-Factorization Inference）
   - 先用 FOL 改变原始矩阵 $M_{|\mathcal{P}|\times|\mathcal{R}|}$ ，再进行普通矩阵分解
2. 一阶谓词子集加入目标函数（Joint Optimization）

Pre-Factorization Inference(FOL 作为预处理)

核心：弥补矩阵的稀疏性，增加收集的一阶逻辑规则与 freebase relation 之间的关联

方法：根据逻辑规则，增加原始矩阵 $M_{|\mathcal{P}|\times|\mathcal{R}|}$ 中值为 1 的元素个数

步骤

- 收集一阶谓词规则
- 对每一条规则，比如 $\mathbf{F} = \forall x, y : r_s(x, y) \Rightarrow (x, y)$
  - 如果 $[(x, y), r_s]$ 上的值为 1，则把 $[(x, y), r_t]$ 上的值置为 1
  - 递归做下去，知道没有新的 1 出现
- 对更新后的矩阵 $M'_{|\mathcal{P}|\times|\mathcal{R}|}$ 进行矩阵分解

Joint Optimization(组合模型)

核心：把收集的一阶逻辑规则加入到矩阵分解的目标函数中

训练集的目标函数：

$$\min_{V} \sum_{\mathcal{F} \in \mathfrak{F}} \mathcal{L}([\mathcal{F}])$$

$[\mathcal{F}]$ is the marginal probability $p(w|V)$ that the formula F is true under the model

$\mathcal{L}([\mathcal{F}] := -\log([\mathcal{F}])$

$p(\mathbf{w}|V) = \prod_{r_m(e_i,e_j)\in w} \pi_m^{e_i,e_j} \prod_{r_m(e_i,e_j)\notin w} (1 - \pi_m^{e_i,e_j})$

边缘分布 (marginal probability)

definition

对多变量的分布函数，针对某个变量进行求和(枚举其他变量的所有情况)，所得到的概率分布

example

联合概率 $P(A,B)$，对 A 的边缘分布为 $P_1(A) = \sum_{b \in B} P(A,b)$，对 B 的边缘分布为 $P_2(B) = \sum_{a \in A} P(a,B)$

边缘分布 (marginal probability)

$$p(\mathbf{w}|V) = \prod_{r_m(e_i,e_j)\in w} \pi_m^{e_i,e_j} \prod_{r_m(e_i,e_j)\notin w} (1 - \pi_m^{e_i,e_j})$$
$$p(\mathbf{w}|V) = \prod f_{r_m(e_i,e_j)} = f_{r_m(e_i,e_j)} \times f_{r_n(e_k,e_l)} \times \dots$$

$$f_{r_m(e_i,e_j)} = \begin{cases} \pi_m^{e_i,e_j} & \text{if } r_m(e_i,e_j) \in w \\ 1 - \pi_m^{e_i,e_j} & \text{if } r_m(e_i,e_j) \notin w \end{cases} \tag{1}$$

- 当 $\mathcal{F}$ 是原子命题时 $[\mathcal{F}] = \pi_m^{e_i,e_j}$
- 当 $\mathcal{F} = \mathcal{A} \wedge \mathcal{B}$, $\mathcal{A}$ 和 $\mathcal{B}$ 是原子命题时, $[\mathcal{F}] = \pi_m^{e_i,e_j} \times \pi_m^{e_i,e_j} = [\mathcal{A}][\mathcal{B}]$
- 当 $\mathcal{F} = \neg\mathcal{A}$, $\mathcal{A}$ 是原子命题时, $[\mathcal{F}] = 1 - [\mathcal{A}]$
- $\mathcal{F} = \mathcal{A} \vee \mathcal{B} = 1 - (\neg\mathcal{A}) \wedge (\neg\mathcal{B})$

$$[\mathcal{A} \vee \mathcal{B}] = [\mathcal{A}] + [\mathcal{B}] - [\mathcal{A}][\mathcal{B}]$$
$$[\mathcal{A} \Rightarrow \mathcal{B}] = [\mathcal{A}]([\mathcal{B}] - 1) + 1$$

...

Joint Optimization(组合模型)

目标函数:

$$\min_V \sum_{\mathcal{F} \in \mathfrak{F}} \mathcal{L}([\mathcal{F}])$$

使用随机梯度下降(stochastic gradient descent)求解

- 对任意一个 $\mathcal{F}$, 其只和实体对向量、谓词向量有关
- 对任意 $\mathcal{L}([\mathcal{F}])$ 只要求 $\partial \mathcal{L}([\mathcal{F}])/\partial v_{r_m}$ 和 $\partial \mathcal{L}([\mathcal{F}])/\partial v_{(e_i, e_j)}$

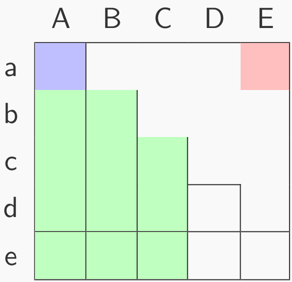
A
B
C
D
E
a
b
c
d
e